文件 » 下载中间件

# 下载中间件

下载器中间件是Scrapy的请求/响应处理的钩子框架。它是一个轻量级的低级系统,用于全局改变Scrapy的请求和响应。

# 激活下载中间件

要激活下载程序中间件组件,请将其添加到 downLoader\_MIDDLEWARES 设置中,该设置是一个 dict,其键是中间件类路径,其值是中间件命令。

#### 这是一个例子:

```
DOWNLOADER_MIDDLEWARES = {
   'myproject.middlewares.CustomDownloaderMiddleware': 543,
}
```

该 DOWNLOADER\_MIDDLEWARES 设置与 DOWNLOADER\_MIDDLEWARES\_BASE Scrapy中定义的设置合并(并不意味着被覆盖),然后按顺序排序,以获得已启用的中间件的最终排序列表:第一个中间件是靠近引擎的中间件,最后一个是更接近引擎的中间件到下载器。换句话说, process\_request() 将以增加的中间件顺序(100,200,300, ...) process\_response() 调用每个中间件的方法,并且将按递减顺序调用每个中间件的方法。

要确定分配给中间件的顺序,请参阅 DOWNLOADER\_MIDDLEWARES\_BASE 设置并根据要插入中间件的位置选择值。订单很重要,因为每个中间件执行不同的操作,您的中间件可能依赖于应用的某些先前(或后续)中间件。

如果要禁用内置中间件( downLoader\_MIDDLEWARES\_BASE 默认情况下定义和启用的中间件 ),则必须在项目的 downLoader\_MIDDLEWARES 设置中定义它并将None指定 为其值。例如,如果要禁用用户代理中间件:

```
DOWNLOADER_MIDDLEWARES = {
    'myproject.middlewares.CustomDownloaderMiddleware': 543,
    'scrapy.downloadermiddlewares.useragent.UserAgentMiddleware': None,
}
```

最后,请记住,可能需要通过特定设置启用某些中间件。有关详细信息,请参阅每个中间件 文档。

# 2018/10编写自己的下载中间件

每个中间件组件都是一个Python类,它定义了以下一个或多个方法:

## scrapy.downloadermiddlewares.DownloaderMiddleware

#### **9**注意

仟何下载器中间件方法也可能返回延迟。

#### process\_request ( 清求, 蜘蛛)

对于通过下载中间件的每个请求,都会调用此方法。

process\_request() 应该:返回 None , 返回一个 Response 对象, 返回一个 Request 对象, 或者提升 IgnoreRequest 。

如果它返回 None , Scrapy将继续处理此请求,执行所有其他中间件,直到最后,相应的下载程序处理程序被称为执行的请求(并且其响应已下载)。

如果它返回一个 Response 对象,Scrapy将不会打扰*任何*其他 process\_request() 或 process\_exception() 方法,或适当的下载功能; 它会回复那个回应。 process\_response() 安装中间件的方法总是在每个响应上调用。

如果它返回一个 Request 对象,Scrapy将停止调用process\_request方法并重新安排返回的请求。执行新返回的请求后,将在下载的响应上调用相应的中间件链。

如果它引发 IgnoreRequest 异常,将 process\_exception() 调用已安装的下载中间件的 方法。如果它们都不处理异常, Request.errback 则调用request()的errback函数。如果没有代码处理引发的异常,则会忽略它并且不会记录(与其他异常不同)。

**参数:** • request ( Request Object ) - 正在处理的请求

• **spider** ( **Spider** object ) - 此请求所针对的蜘蛛

#### process response ( 清求, 响应, 蜘蛛)

process\_response() 应该:返回一个 Response 对象,返回一个 Request 对象或引发一个 IgnoreRequest 异常。

如果它返回a Response (它可能是相同的给定响应,或者是全新的响应),则该响应将继续与 process\_response()链中的下一个中间件一起处理。

如果它返回一个 Request 对象,则暂停中间件链,并重新安排返回的请求以便将来下载。这与从中返回请求的行为相同 process request()。

如果它引发 IgnoreRequest 异常,Request.errback 则调用request()的errback函数。如果没有代码处理引发的异常,则会忽略它并且不会记录(与其他异常不同)。

- → 下载中间件 Scrapy 1.5.1文档 **参数: • request**(是一个 Request 对象) - 发起响应的请求
  - response ( Response object ) 正在处理的响应
  - spider ( Spider object ) 此响应所针对的蜘蛛

#### process\_exception(清求,异常,蜘蛛)

process\_exception() 下载处理程序或 process\_request() (从下载中间件)引发异常(包括 IgnoreRequest 异常)时Scrapy调用

process\_exception() 应该返回:要么 None , 一个 Response 对象或 Request 对象。

如果它返回 None , Scrapy将继续处理此异常,执行任何其他 process\_exception() 已安装的中间件方法,直到没有剩下中间件并且默认异常处理开始。

如果它返回一个 Response 对象 , process\_response() 则启动已安装的中间件的方法链 , 并且Scrapy不会打扰调用任何其他 process\_exception() 中间件方法。

如果它返回一个 Request 对象,则重新安排返回的请求以便将来下载。这会停止执行 process\_exception() 中间件的方法,就像返回响应一样。

参数: request (是一个 Request 对象) - 生成异常的请求

- exception (一个 Exception 对象) 引发的异常
- spider ( Spider object ) 此请求所针对的蜘蛛

from crawler ( cls , crawler )

如果存在,则调用此类方法以从a创建中间件实例 Crawler 。它必须返回一个新的中间件实例。Crawler对象提供对所有Scrapy核心组件的访问,如设置和信号;它是中间件访问它们并将其功能挂钩到Scrapy的一种方式。

参数: crawler ( Crawler object ) - 使用此中间件的爬网程序

# 内置下载中间件参考

此页面描述了Scrapy附带的所有下载中间件组件。有关如何使用它们以及如何编写自己的下载程序中间件的信息,请参阅下载程序中间件使用指南。

有关默认启用的组件列表(及其订单),请参阅 DOWNLOADER\_MIDDLEWARES\_BASE 设置。

### CookiesMiddleware

#### ## scrapy.downloadermiddlewares.cookies.CookiesMiddleware ## scrapy.downloadermiddlewares.cookies.CookiesMiddleware ## scrapy.downloadermiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.Cookies.CookiesMiddlewares.cookies.CookiesMiddlewares.cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookies.Cookie

此中间件可用于处理需要cookie的站点,例如使用会话的站点。它跟踪Web服务器发送的cookie,并在后续请求(来自该蜘蛛)上发回它们,就像Web浏览器一样。

- COOKIES ENABLED
- COOKIES DEBUG

### 每个蜘蛛多个cookie会话

#### 0.15版本的新功能。

通过使用 cookiejar Request meta键,支持为每个蜘蛛保留多个cookie会话。默认情况下,它使用单个cookie jar(会话),但您可以传递标识符以使用不同的cookie。

例如:

```
for i, url in enumerate(urls):
    yield scrapy.Request(url, meta={'cookiejar': i},
        callback=self.parse_page)
```

请记住, cookiejar 元键不是"粘性"。您需要在后续请求中继续传递它。例如:

```
def parse_page(self, response):
    # do some processing
    return scrapy.Request("http://www.example.com/otherpage",
        meta={'cookiejar': response.meta['cookiejar']},
        callback=self.parse_other_page)
```

### **COOKIES\_ENABLED**

默认: True

是否启用cookie中间件。如果禁用,则不会将cookie发送到Web服务器。

请注意,尽管 COOKIES\_ENABLED 设置值如果 Request. meta['dont\_merge\_cookies'] 评估 True 请求,cookie将不会发送到Web服务器,并且收到的cookie Response 将 不会与现有cookie合并。

有关更多详细信息,请参阅 cookies 参数 Request 。

#### COOKIES\_DEBUG

默认: False

如果启用, Scrapy将记录请求中发送的所有cookie(即 cookie 标题)和响应中收到的所有

#### **DefaultHeadersMiddleware**

# scrapy.downloadermiddlewares.defaultheaders.DefaultHeadersMiddleware

此中间件设置设置中指定的所有默认请求标头 DEFAULT\_REQUEST\_HEADERS 。

#### DownloadTimeoutMiddleware

# scrapy.downloadermiddlewares.downloadtimeout.DownloadTimeoutMiddleware

此中间件为 DOWNLOAD\_TIMEOUT 设置或 download\_timeout spider属性中指定的请求设置下载超时。

#### O 注意

您还可以使用 download\_timeout Request.meta键设置每个请求的下载超时;即使禁用 DownloadTimeoutMiddleware,也支持此功能。

# HttpAuthMiddleware

## scrapy.downloadermiddlewares.httpauth.HttpAuthMiddleware
## scrapy.downloadermiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.HttpAuthMiddlewares.httpauth.httpAuthMiddlewares.httpauth.httpAuthMiddlewares.httpauth.httpAuthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddlewares.httpauthMiddl

此中间件使用基本访问身份验证(也称为HTTP身份验证)对从某些蜘蛛生成的所有请求进行身份验证。

要从某些蜘蛛启用HTTP身份验证,请设置这些蜘蛛的 http\_user 和 http\_pass 属性。

例:

```
from scrapy.spiders import CrawlSpider

class SomeIntranetSiteSpider(CrawlSpider):

  http_user = 'someuser'
  http_pass = 'somepass'
  name = 'intranet.example.com'

# .. rest of the spider code omitted ...
```

### HttpCacheMiddleware

### ## scrapy.downloadermiddlewares.httpcache.HttpCacheMiddleware ## scrapy.downloadermiddlewares.httpcache.HttpCacheMiddleware.html ## scrapy.downloadermiddlewares.html ## scrapy.downloadermidd

此中间件为所有HTTP请求和响应提供低级缓存。它必须与缓存存储后端以及缓存策略结合使用。

Scrapy附带三个HTTP缓存存储后端:

- 文件系统存储后端(默认)
- DBM存储后端
- LevelDB存储后端

您可以使用该 HTTPCACHE\_STORAGE 设置更改HTTP缓存存储后端。或者您也可以实现自己的存储后端。

Scrapy附带两个HTTP缓存策略:

- RFC2616政策
- 虚拟政策(默认)

您可以使用该 HTTPCACHE\_POLICY 设置更改HTTP缓存策略。或者您也可以实施自己的政策。 您还可以使用 dont\_cache 元键等于True来避免在每个策略上缓存响应。

# 虚拟政策(默认)

此策略不了解任何HTTP Cache-Control指令。每个请求及其相应的响应都被缓存。当再次看到相同的请求时,将返回响应,而不从Internet传输任何内容。

Dummy策略对于更快地测试蜘蛛非常有用(无需每次都等待下载),并且当Internet连接不可用时,可以离线尝试蜘蛛。我们的目标是能够"重播"蜘蛛来看,正是因为它跑前。

要使用此政策,请设置:

• HTTPCACHE\_POLICY 至 scrapy.extensions.httpcache.DummyPolicy

# RFC2616策略

此策略提供符合RFC2616的HTTP缓存,即具有HTTP缓存控制感知,旨在生产并用于连续运行,以避免下载未修改的数据(以节省带宽和加速爬网)。

#### 实施的内容:

• 不要尝试使用no-store cache-control指令集存储响应/请求

2018/10/15 如果为新响应设置了no-cache cache-cont的槽令 Scr则不要拟缓存提供响应

- 从max-age cache-control指令计算新鲜度生命周期
- 从Expires响应头计算新鲜度生命周期
- 从Last-Modified响应头开始计算新鲜度生命周期 (Firefox使用的启发式)
- 从Age响应标头计算当前年龄
- 从Date标头计算当前年龄
- 根据Last-Modified响应头重新验证过时响应
- 根据ETag响应头重新验证过时响应
- 为任何收到的响应设置日期标题
- 支持请求中的max-stale cache-control指令

这允许蜘蛛配置完整的RFC2616缓存策略,但避免在逐个请求的基础上重新验证,同时保持符合HTTP规范。

#### 例:

添加Cache-Control: max-stale = 600到Request标头,以接受超过其到期时间不超过600秒的响应。

另见: RFC2616,14.9.3

#### 缺什么:

- *Pragma:无缓存*支持https://www.w3.org/Protocols/rfc2616/rfc2616-sec14.html#sec14.9.1
- 不同的标题支持https://www.w3.org/Protocols/rfc2616/rfc2616-sec13.html#sec13.6
- 更新或删除后失效https://www.w3.org/Protocols/rfc2616/rfc2616-sec13.html#sec13.10
- ......可能还有其他...

#### 要使用此政策,请设置:

• HTTPCACHE\_POLICY 至 scrapy.extensions.httpcache.RFC2616Policy

# 文件系统存储后端 (默认)

文件系统存储后端可用于HTTP缓存中间件。

#### 要使用此存储后端,请设置:

• HTTPCACHE\_STORAGE 至 scrapy.extensions.httpcache.FilesystemCacheStorage

每个请求/响应对都存储在包含以下文件的不同目录中:

- 2018/10/15 request body 普通请求机构 下载中间件 - Scrapy 1.5.1文档
  - request headers 请求标头 (原始HTTP格式 )
  - response body 简单的回应机构
  - response headers 请求标头 (原始HTTP格式)
  - meta Python repr() 格式的缓存资源的一些元数据(grep友好格式)
  - pickled meta 相同的元数据, meta 但为更有效的反序列化而腌制

目录名称来自请求指纹(请参阅参考资料 scrapy.utils.request.fingerprint ),并且使用一个 级别的子目录来避免在同一目录中创建太多文件(这在许多文件系统中效率低下)。示例目 录可以是:

/path/to/cache/dir/example.com/72/72811f648e718090f041317756c03adb0ada46c7

### DBM存储后端

版本0.13中的新功能。

一个DBM存储后端也可用于HTTP缓存中间件。

默认情况下,它使用anydbm模块,但您可以使用该 HTTPCACHE DBM MODULE 设置更改它。

要使用此存储后端,请设置:

HTTPCACHE STORAGE 至 scrapy.extensions.httpcache.DbmCacheStorage

### LevelDB存储后端

版本0.23中的新功能。

一个性LevelDB存储后端也可用于HTTP缓存中间件。

建议不要将此后端用于开发,因为只有一个进程可以同时访问LevelDB数据库,因此您无法运 行爬网并为同一个蜘蛛并行打开scrapy shell。

#### 要使用此存储后端:

- 设置 HTTPCACHE\_STORAGE 为 scrapy.extensions.httpcache.LeveldbCacheStorage
- 安装LevelDB python绑定之类的 pip install leveldb

# HTTPCache中间件设置

的 HttpCacheMiddleware 可以通过以下设置来配置:

版本0.11中的新功能。

默认: False

是否启用HTTP缓存。

在版本0.11中更改:在0.11之前, HTTPCACHE\_DIR 用于启用缓存。

#### HTTPCACHE\_EXPIRATION\_SECS

默认: ૄ

缓存请求的到期时间,以秒为单位。

超过此时间的缓存请求将被重新下载。如果为零,则缓存的请求将永不过期。

在版本0.11中更改:在0.11之前,零表示缓存的请求始终过期。

#### HTTPCACHE\_DIR

默认: 'httpcache'

用于存储(低级)HTTP缓存的目录。如果为空,则将禁用HTTP缓存。如果给出相对路径,则相对于项目数据dir。有关详细信息,请参阅:Scrapy项目的默认结构。

#### HTTPCACHE\_IGNORE\_HTTP\_CODES

版本0.10中的新功能。

默认: []

不要使用这些HTTP代码缓存响应。

#### HTTPCACHE\_IGNORE\_MISSING

默认: False

如果启用,将忽略未在缓存中找到的请求而不是下载。

#### HTTPCACHE\_IGNORE\_SCHEMES

默认: ['file']

不要使用这些URI方案缓存响应。

#### HTTPCACHE\_STORAGE

默认: 'scrapy.extensions.httpcache.FilesystemCacheStorage'

实现缓存存储后端的类。

#### HTTPCACHE DBM MODULE

版本0.13中的新功能。

默认: 'anydbm'

要在DBM存储后端中使用的数据库模块。此设置特定于DBM后端。

#### HTTPCACHE\_POLICY

版本0.18中的新功能。

默认: 'scrapy.extensions.httpcache.DummyPolicy'

实现缓存策略的类。

#### HTTPCACHE\_GZIP

版本1.0中的新功能。

默认: False

如果启用,将使用gzip压缩所有缓存的数据。此设置特定于Filesystem后端。

#### HTTPCACHE\_ALWAYS\_STORE

版本1.1中的新功能。

默认: False

如果启用,将无条件地缓存页面。

2018/1蜘蛛可能希望在缓存中提供所有响应,以便将来使用空配拾5℃的料rol:max-stale。DummyPolicy缓存所有响应,但从不重新验证它们,有时需要更细微的策略。

此设置仍然遵循Cache-Control:响应中的no-store指令。如果您不想这样做,请在您提供给缓存中间件的响应中的Cache-Control标头中过滤no-store。

### HTTPCACHE\_IGNORE\_RESPONSE\_CACHE\_CONTROLS

版本1.1中的新功能。

默认: []

要忽略的响应中的Cache-Control指令列表。

站点通常设置"无存储","无缓存","必须重新验证"等,但如果它遵守这些指令,蜘蛛可以生成的流量会感到不安。这允许有选择地忽略已知对正在被爬网的站点不重要的Cache-Control指令。

我们假设蜘蛛不会在请求中发出Cache-Control指令,除非它实际需要它们,因此不会过滤请求中的指令。

# HttpCompressionMiddleware

## scrapy.downloadermiddlewares.httpcompression.HttpCompressionMiddleware

## scrapy.downloadermiddlewares.httpcompression.HttpCompressionMiddlewares.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.httpcompression.htt

该中间件允许从网站发送/接收压缩 (gzip, deflate)流量。

如果安装了brotlipy,此中间件还支持解码brotli压缩响应。

# HttpCompressionMiddleware设置

#### COMPRESSION\_ENABLED

默认: True

是否启用压缩中间件。

# HttpProxyMiddleware

版本0.8中的新功能。

scrapy.downloadermiddlewares.httpproxy.HttpProxyMiddleware

此中间件通过设置对象的 proxy 元值来设置用于请求的HTTP代理 Request 。

- 2018/10/15 http\_proxy https proxy
  - no proxy

您还可以将 proxy 每个请求的元键设置为类似 http://some proxy server:port 或的值 http://username:password@some proxy server:port 。请记住,此值将优先于 http proxy / https proxy environment变量,并且还将忽略 no proxy 环境变量。

#### **RedirectMiddleware**

# scrapv.downloadermiddlewares.redirect.RedirectMiddleware

该中间件根据响应状态处理请求的重定向。

可以在 redirect urls Request.meta 密钥中找到请求经过的URL(在重定向时)。

该 RedirectMiddleware 可通过以下设置进行配置(详情参见设置文档):

- REDIRECT ENABLED
- REDIRECT MAX TIMES

如果 Request.meta 将 dont\_redirect 键设置为True,则此中间件将忽略该请求。

如果要在spider中处理一些重定向状态代码,可以在 handle httpstatus list spider属性中指定 这些代码。

例如,如果您希望重定向中间件忽略301和302响应(并将它们传递给您的蜘蛛),您可以这 样做:

```
class MySpider(CrawlSpider):
    handle_httpstatus_list = [301, 302]
```

所述 handle httpstatus list 的键 Request.meta 也可以被用于指定的响应代码,以允许在每个请 求基础。您还可以设置meta键 handle\_httpstatus\_all 来 True ,如果你想以允许请求的任何响 应代码。

# RedirectMiddleware设置

#### REDIRECT\_ENABLED

版本0.13中的新功能。

默认: True

#### REDIRECT\_MAX\_TIMES

默认: 20

单个请求将遵循的最大重定向数。

### MetaRefreshMiddleware

## scrapy.downloadermiddlewares.redirect.MetaRefreshMiddleware

## scrapy.downloadermiddlewares.redirect.MetaRefreshMiddlewares.

## scrapy.downloadermiddlewares.redirect.MetaRefreshMiddlewares.

## scrapy.downloadermiddlewares.redirect.MetaRefreshMiddlewares.

## scrapy.downloadermiddlewares.

## scrapy.downloadermiddlewares.redirect.MetaRefreshMiddlewares.

## scrapy.downloadermiddlewares.

## scrapy.dow

此中间件基于元刷新html标记处理请求的重定向。

该 MetaRefreshMiddleware 可通过以下设置进行配置(详情参见设置文档):

- METAREFRESH\_ENABLED
- METAREFRESH\_MAXDELAY

该中间件服从 REDIRECT\_MAX\_TIMES 设置, dont\_redirect 并 redirect\_urls 按照描述请求元密 钥 RedirectMiddleware

### MetaRefreshMiddleware设置

#### **METAREFRESH\_ENABLED**

版本0.17中的新功能。

默认: True

是否启用Meta Refresh中间件。

#### **METAREFRESH\_MAXDELAY**

默认: 100

跟随重定向的最大元刷新延迟(以秒为单位)。有些站点使用元刷新来重定向到会话过期页面,因此我们将自动重定向限制为最大延迟。

# RetryMiddleware

## scrapy.downloadermiddlewares.retry.RetryMiddleware

## scrapy.downloadermiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retry.RetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlewares.retryRetryMiddlew

一种中间件,用于重试可能由临时问题(如连接超时或HTTP 500错误)引起的失败请

该 RetryMiddleware 可通过以下设置进行配置(详情参见设置文档):

- RETRY ENABLED
- RETRY\_TIMES
- RETRY\_HTTP\_CODES

如果 Request.meta 将 dont\_retry 键设置为True,则此中间件将忽略该请求。

### 重试中间件设置

#### **RETRY\_ENABLED**

版本0.13中的新功能。

默认: True

是否启用重试中间件。

#### **RETRY\_TIMES**

默认: 2

除第一次下载外,最多重试次数。

每个请求也可以使用 max\_retry\_times 属性指定最大重试次数 Request.meta 。初始化时, max\_retry\_times 元键优先于 RETRY\_TIMES 设置。

#### RETRY\_HTTP\_CODES

默认: [500, 502, 503, 504, 408]

要重试的HTTP响应代码。始终重试其他错误(DNS查找问题,连接丢失等)。

在某些情况下,您可能希望添加400,RETRY\_HTTP\_CODES 因为它是用于指示服务器过载的公共代码。默认情况下不包括它,因为HTTP规范说明了这一点。

#### RobotsTxtMiddleware

## scrapy.downloadermiddlewares.robotstxt.RobotsTxtMiddleware

## scrapy.downloadermiddlewares.robotsTxtMiddleware

## scrapy.downloadermiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddlewares.robotsTxtMiddleware

要确保Scrapy尊重robots.txt,请确保已启用中间件并启用该 ROBOTSTXT OBEY 设置。

如果 Request.meta 将 dont\_obey\_robotstxt 密钥设置为True,则即使 ROBOTSTXT\_OBEY 启用了该中间件,该请求也将被忽略。

#### **DownloaderStats**

### ## scrapy.downloadermiddlewares.stats.DownloaderStats ## scrapy.downloaderStats

中间件,用于存储通过它的所有请求,响应和异常的统计信息。

要使用此中间件,您必须启用该 downLoader\_stats 设置。

### UserAgentMiddleware

#### # scrapy.downloadermiddlewares.useragent.UserAgentMiddleware

允许蜘蛛覆盖默认用户代理的中间件。

为了使蜘蛛覆盖默认用户代理,必须设置其user\_agent属性。

# AjaxCrawlMiddleware

#### ## scrapy.downloadermiddlewares.ajaxcrawl.AjaxCrawlMiddleware ## scrapy.downloadermiddlewares.ajaxcrawl.AjaxCrawlMiddlewares.ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcrawl.Ajaxcra

基于元片段html标记找到"AJAX可抓取"页面变体的中间件。有关详细信息,请参阅https://developers.google.com/webmasters/ajax-crawling/docs/getting-started。

#### O 注意

'http://example.com/!#foo=bar' 即使没有这个中间件,Scrapy也会为URL找到"AJAX可抓取"页面。当URL不包含时,AjaxCrawlMiddleware是必需的 '!#' 。这通常是"索引"或"主要"网站页面的情况。

# AjaxCrawlMiddleware设置

#### AJAXCRAWL\_ENABLED

版本0.21中的新功能。

默认: False

是否启用AjaxCrawlMiddleware。您可能希望为广泛爬网启用它。

# HttpProxyMiddleware设置

### HTTPPROXY\_ENABLED

默认: True

是否启用 HttpProxyMiddleware 。

### HTTPPROXY\_AUTH\_ENCODING

默认: "latin-1"

代理身份验证的默认编码 HttpProxyMiddleware 。